

Sistemas de recomendación

Arias, Blanc, Comelli

2026

Contents

1	Preliminares/Motivación	1
2	Gradiente Descendente y Descendente estocástico.	3
3	The Second Chapter	6

Chapter 1

Preliminares/Motivación

Dada una matriz R , de $n \times m$, queremos poder factorizarla como producto de otras. Estas otras, queremos que sean más pequeñas que R o que tengan ciertas propiedades que R no tiene, es decir, buscamos a priori, U y V , tales que,

$$R \approx UV.$$

Para dar cuenta de qué tan buena es nuestra aproximación, hacemos uso de la norma de Frobenius. Por lo tanto, queremos U, V . Tales que la diferencia sea tan pequeña como sea posible, es decir,

$$\|R - UV\|_F.$$

Por lo tanto, podemos pensarlo como un problema de optimización, donde queremos minimizar $J = \|R - UV\|_F$.

Nuevamente, dependiendo de cómo es la naturaleza de los datos de la matriz R , pediremos que U, V , etc. tengan ciertas propiedades. Por ejemplo, si queremos que nuestras matrices sean ortonormales entre sí y que sean del menor rango posible, podemos hacer uso de la *SVD* (singular value decomposition), es decir estaríamos resolviendo el problema:

$$\text{Minimizar } J = \|R - U_k \Sigma_k V_k^T\|_F.$$

Sujeto a: U, V ortonormales, k el rango de R .

Ahora bien, nuestra matriz R no se trata de números sin significado alguno, en R hay codificados datos sobre la realidad, por ejemplo, podríamos pensar que las filas de R son usuarios de netflix y las columnas son películas. Aquí los datos r_{ij} serían o bien si el usuario ha visto una película o bien cuanta puntuación ha dado un usuario a una película. Tomando este ultimo caso, r_{ij} será la puntuación del usuario i en la película j .

Nuestro objetivo no se trata de aproximar R pues si ya conozco R no hay nada que aproximar. El problema es justamente ese. Un usuario puede ver 10, 20 o quizás 100 películas pero hay miles, por lo tanto en la matriz R habrán pocos datos conocidos (las puntuaciones de las películas que vio) y muchísimos datos desconocidos (puntuaciones de películas que no vio). La idea de los sistemas de recomendación es poder ser capaz

de determinar, a través de los datos conocidos, qué películas que el usuario no ha visto, le podrían gustar más.

Para dar respuesta a esta pregunta hay que, en primer lugar, rellenar esos datos, pues no podemos trabajar con matrices que le faltan datos. Hemos de rellenar las matrices de manera coherente, dependiendo de la naturaleza del objeto.

Para comenzar con este viaje de recomendaciones, veremos un método sencillo y algo costoso pero que funciona bien, Veremos el método del Gradiente Descendente (GD).

Chapter 2

Gradiente Descendente y Descendente estocástico.

Table 2.1: Convergence and Performance Comparison ($K = 2$ vs. $K = 8$)

Algorithm	K	Iterations	Final RMSE	RMSE Change (Δ)	Status
Batch GD	2	647	1.2855	3.7×10^{-5}	Converged
SGD (Aggarwal 2016)	2	65	0.7445	1.0×10^{-5}	Converged
Batch GD (w/ reg.)	2	1000	1.2442	—	Max Iterations
SGD (w/ reg.)	2	39	0.8009	1.3×10^{-5}	Converged
Batch GD	8	1000	0.6614	—	Max Iterations
SGD (Aggarwal 2016)	8	56	0.5905	1.7×10^{-5}	Converged
Batch GD (w/ reg.)	8	1000	0.6691	—	Max Iterations
SGD (w/ reg.)	8	100	0.6509	5.5×10^{-5}	Converged

Table 2.2: Top 10 Recommendations for User 1 Across Latent Factors
($K = 2, 8$)

Rank	Movie ID	Rating	Title	Genres
Latent Factors: $K = 2$				
<i>1) Matrix-based Batch Gradient Descent</i>				
1	136850	8.93	Villain (1971)	Crime Drama Thriller
2	318	8.28	Shawshank Redemption, The (1994)	Crime Drama
3	40491	8.11	Match Factory Girl, The (1990)	Comedy Drama
4	141718	7.76	Deathgasm (2015)	Comedy Horror
5	81535	7.43	Saw VII 3D: The Final Chapter (2010)	Horror Mystery Thriller
6	156605	7.29	Paterson (2016)	(no genres listed)
7	102217	7.29	Bill Hicks: Revelations (1993)	Comedy

Continued on next page...

Table 2.2 continued from previous page

Rank	Movie ID	Rating	Title	Genres
8	876	7.19	Supercop 2 (Project S) (1993)	Action Comedy Crime Thriller
9	3567	7.17	Bossa Nova (2000)	Comedy Drama Romance
10	92494	7.08	Dylan Moran: Monster (2004)	Comedy Documentary
<i>2) SGD Algorithm (Aggarwal 2016)</i>				
1	40491	8.27	Match Factory Girl, The (1990)	Comedy Drama
2	136850	7.59	Villain (1971)	Crime Drama Thriller
3	3567	7.48	Bossa Nova (2000)	Comedy Drama Romance
4	156605	7.39	Paterson (2016)	(no genres listed)
5	67618	7.10	Strictly Sexual (2008)	Comedy Drama Romance
6	8477	7.08	Jetée, La (1962)	Romance Sci-Fi
7	141718	6.85	Deathgasm (2015)	Comedy Horror
8	68536	6.79	Stanley Kubrick: A Life in Pictures (2001)	Documentary
9	391	6.58	Jason's Lyric (1994)	Crime Drama
10	57502	6.54	Cat Soup (Nekojiru-so) (2001)	Adv Anim Drama Horror
<i>3) Matrix-based Batch Gradient Descent with Regularization</i>				
1	136850	9.27	Villain (1971)	Crime Drama Thriller
2	40491	8.07	Match Factory Girl, The (1990)	Comedy Drama
3	141718	7.81	Deathgasm (2015)	Comedy Horror
4	102217	7.53	Bill Hicks: Revelations (1993)	Comedy
5	130482	7.40	Too Late for Tears (1949)	Crime Drama Film-Noir Myst Thril
6	92494	7.27	Dylan Moran: Monster (2004)	Comedy Documentary
7	156605	7.25	Paterson (2016)	(no genres listed)
8	81535	7.23	Saw VII 3D: The Final Chapter (2010)	Horror Mystery Thriller
9	3567	7.17	Bossa Nova (2000)	Comedy Drama Romance
10	107780	7.07	Cats (1998)	Musical
<i>4) SGD Algorithm with Regularization</i>				
1	8477	5.82	Jetée, La (1962)	Romance Sci-Fi
2	6818	5.81	Come and See (1985)	Drama War
3	87234	5.70	Submarine (2010)	Comedy Drama Romance
4	26326	5.55	Holy Mountain, The (1973)	Drama
5	3473	5.50	Jonah Who Will Be 25 in the Year 2000 (1976)	Comedy
6	53	5.47	Lamerica (1994)	Adventure Drama
7	26810	5.47	Bad Boy Bubby (1993)	Drama
8	6460	5.46	Trial, The (Procès, Le) (1962)	Drama
9	177593	5.46	Three Billboards Outside Ebbing, Missouri (2017)	Crime Drama
10	3451	5.46	Guess Who's Coming to Dinner (1967)	Drama

Latent Factors: $K = 8$

1) Matrix-based Batch Gradient Descent

1	86781	8.46	Incendies (2010)	Drama Mystery War
2	318	7.87	Shawshank Redemption, The (1994)	Crime Drama

Continued on next page...

Table 2.2 continued from previous page

Rank	Movie ID	Rating	Title	Genres
3	136850	7.67	Villain (1971)	Crime Drama Thriller
4	116897	7.58	Wild Tales (2014)	Comedy Drama Thriller
5	96829	7.55	Hunt, The (Jagten) (2012)	Drama
6	876	7.27	Supercop 2 (Project S) (1993)	Action Comedy Crime Thriller
7	1354	7.24	Breaking the Waves (1996)	Drama Mystery
8	177765	6.84	Coco (2017)	Adventure Animation Children
9	148	6.81	Awfully Big Adventure, An (1995)	Drama
10	5882	6.74	Treasure Planet (2002)	Adv Anim Child Sci-Fi IMAX
2) SGD Algorithm (Aggarwal 2016)				
1	3567	6.95	Bossa Nova (2000)	Comedy Drama Romance
2	136850	6.61	Villain (1971)	Crime Drama Thriller
3	141718	6.38	Deathgasm (2015)	Comedy Horror
4	876	6.31	Supercop 2 (Project S) (1993)	Action Comedy Crime Thriller
5	951	6.26	His Girl Friday (1940)	Comedy Romance
6	6818	6.24	Come and See (1985)	Drama War
7	306	6.23	Three Colors: Red (1994)	Drama
8	5607	6.23	Son of the Bride (2001)	Comedy Drama
9	7815	6.21	True Stories (1986)	Comedy Musical
10	3086	6.20	Babes in Toyland (1934)	Child Comedy Fantasy Musical
3) Matrix-based Batch Gradient Descent with Regularization				
1	86781	8.10	Incendies (2010)	Drama Mystery War
2	318	7.94	Shawshank Redemption, The (1994)	Crime Drama
3	116897	7.48	Wild Tales (2014)	Comedy Drama Thriller
4	96829	7.37	Hunt, The (Jagten) (2012)	Drama
5	136850	7.32	Villain (1971)	Crime Drama Thriller
6	1354	7.10	Breaking the Waves (1996)	Drama Mystery
7	876	7.06	Supercop 2 (Project S) (1993)	Action Comedy Crime Thriller
8	177765	6.69	Coco (2017)	Adventure Animation Children
9	5882	6.64	Treasure Planet (2002)	Adv Anim Child Sci-Fi IMAX
10	148	6.60	Awfully Big Adventure, An (1995)	Drama
4) SGD Algorithm with Regularization				
1	3567	6.13	Bossa Nova (2000)	Comedy Drama Romance
2	6818	6.09	Come and See (1985)	Drama War
3	8477	5.97	Jetée, La (1962)	Romance Sci-Fi
4	26326	5.92	Holy Mountain, The (1973)	Drama
5	3379	5.82	On the Beach (1959)	Drama
6	5490	5.79	The Big Bus (1976)	Action Comedy
7	6201	5.78	Lady Jane (1986)	Drama Romance
8	132333	5.77	Seve (2014)	Documentary Drama
9	33649	5.77	Saving Face (2004)	Comedy Drama Romance
10	7767	5.70	Best of Youth, The (2003)	Drama

Chapter 3

The Second Chapter